Wstęp do Eksploracji Danych

Politechnika Warszawska

Anna Kozak

Grafy

Grafy

- graph $G = (V, E)$
- vertices $V = \{v_1, v_2, \ldots, v_n\}$
- edge $E = \{e_1, e_2, \ldots, e_m\}$

Reprezentacje

$$
\begin{aligned}
V &= \{v_1, v_2, v_3, v_4, v_5, v_6, v_7, v_8, v_9, v_{10}\} \\
E &= \{\{v_1, v_2\}, \{v_1, v_8\}, \{v_2, v_3\}, \{v_3, v_5\}, \{v_3, v_9\}, \\
&\quad \{v_3, v_{10}\}, \{v_4, v_5\}, \{v_4, v_6\}, \{v_4, v_9\}, \{v_5, v_8\}, \\
&\quad \{v_6, v_8\}, \{v_6, v_9\}, \{v_7, v_8\}, \{v_7, v_9\}, \{v_8, v_{10}\}, \\
&\quad \{v_9, v_{10}\}\}
\end{aligned}
$$

Reprezentacje

v_1:	v_2, v_8	v_6:	v_4, v_8, v_9
v_2:	v_1, v_3	v_7:	v_8, v_9
v_3:	v_2, v_5, v_9, v_{10}	v_8:	$v_1, v_5, v_6, v_7, v_9, v_{10}$
v_4:	v_5, v_6, v_9	v_9:	$v_3, v_4, v_6, v_7, v_8, v_{10}$
v_5:	v_3, v_4, v_8	v_{10}:	v_3, v_8, v_9

Reprezentacje

$$
\begin{pmatrix}
0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\
1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\
0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 1 \\
0 & 0 & 0 & 0 & 1 & 1 & 0 & 0 & 1 & 0 \\
0 & 0 & 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\
0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 1 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 \\
1 & 0 & 0 & 0 & 1 & 1 & 1 & 0 & 1 & 1 \\
0 & 0 & 1 & 1 & 0 & 1 & 1 & 1 & 0 & 1 \\
0 & 0 & 1 & 0 & 0 & 0 & 0 & 1 & 1 & 0
\end{pmatrix}
$$

Reprezentacje

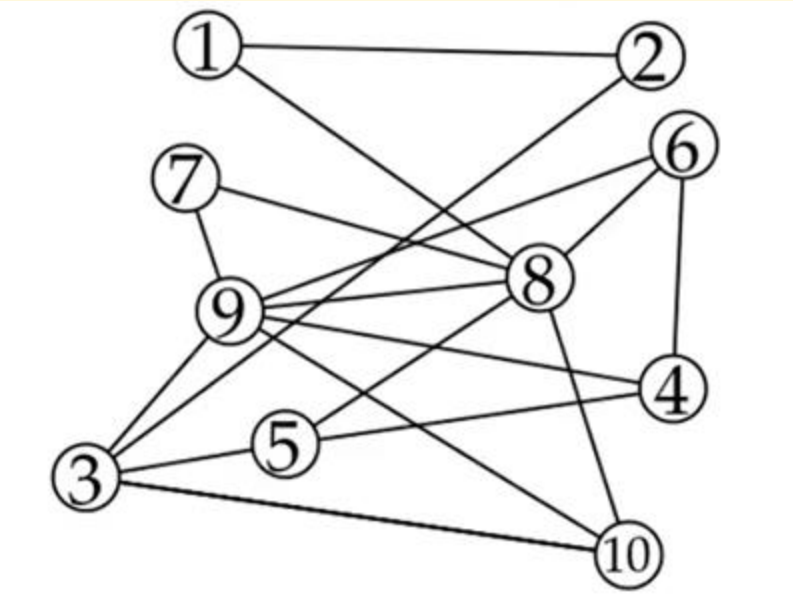

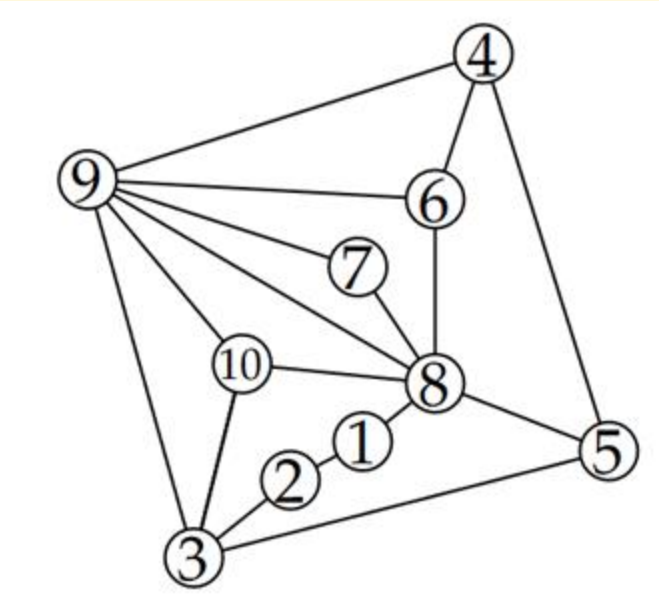

Grafy abstrakcyjne

- sieć społecznościowa
- sieć komunikacyjna
- sieć filogenetyczna

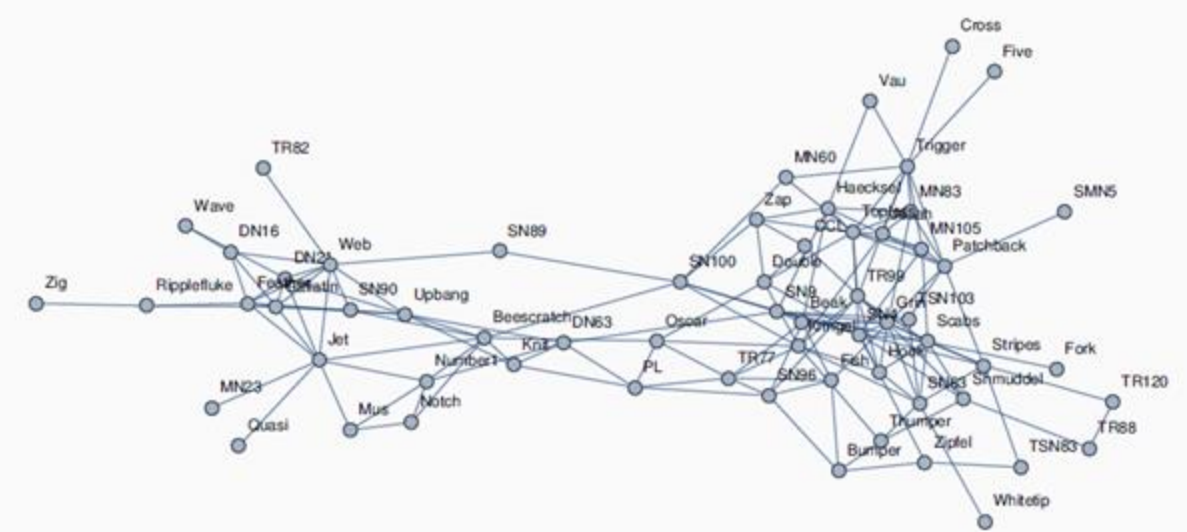

Grafy rzeczywiste

- sieć metra (transportu)
- sieć dróg
- sieć telekomunikacyjna

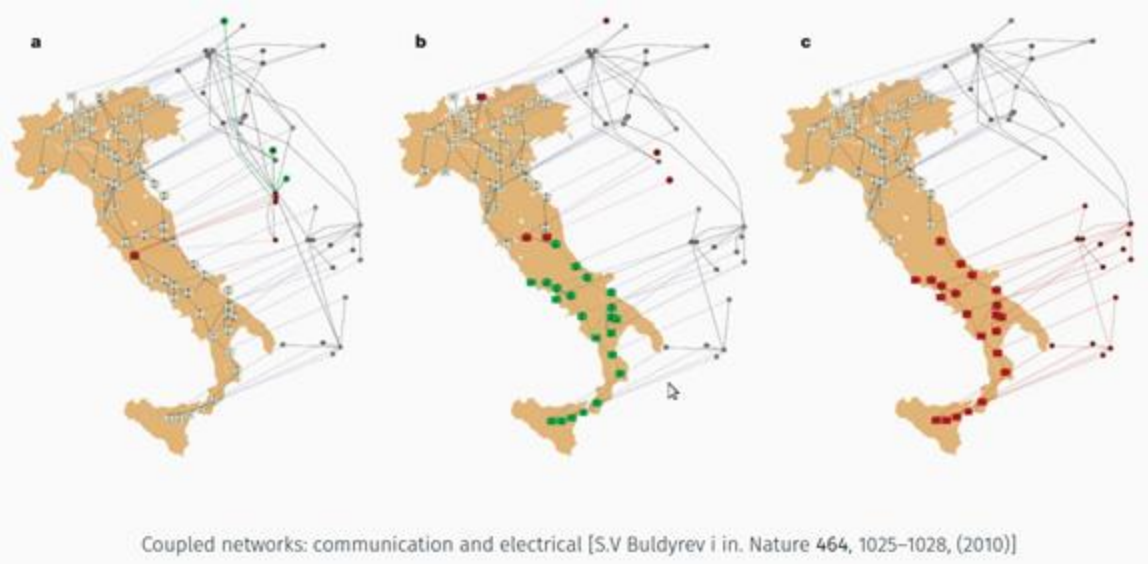

Coupled networks: communication and electrical [S.V Buldyrev i in. Nature 464, 1025–1028, (2010)]

Rodzaje grafów

- grafy proste

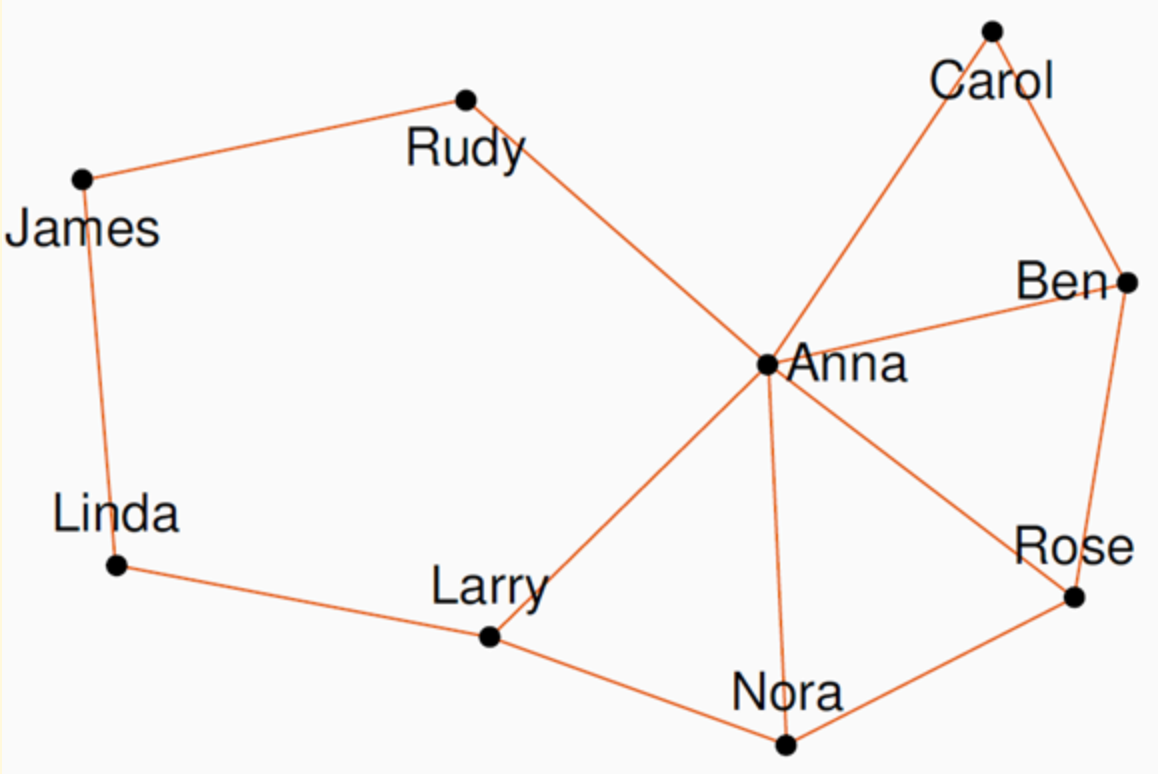

Rodzaje grafów

- grafy proste
- grafy skierowane

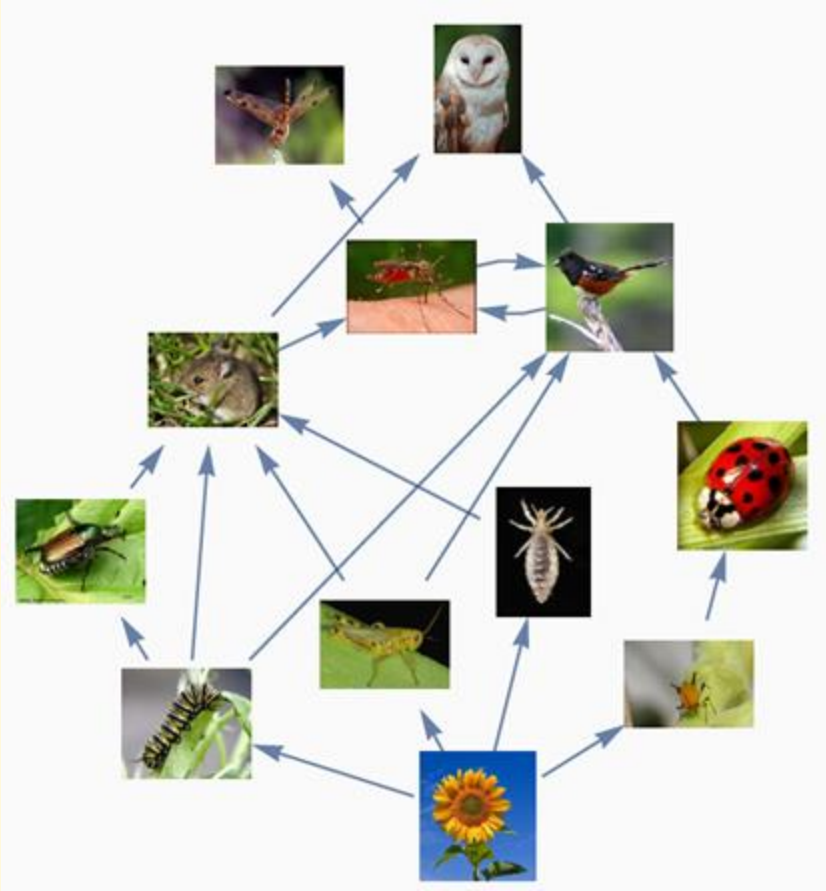

Rodzaje grafów

- grafy proste
- grafy skierowane
- multigrafy

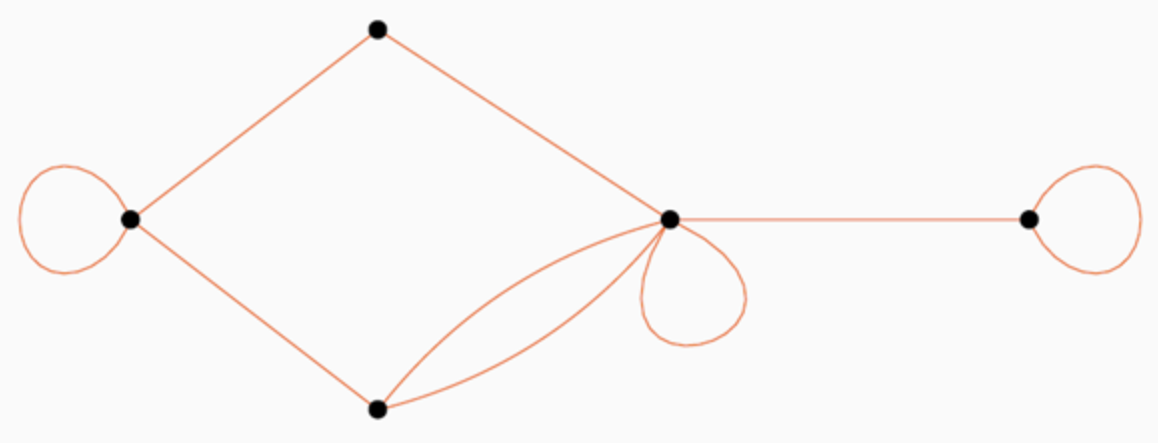

Rodzaje grafów

- grafy proste
- grafy skierowane
- multigrafy
- grafy ważone

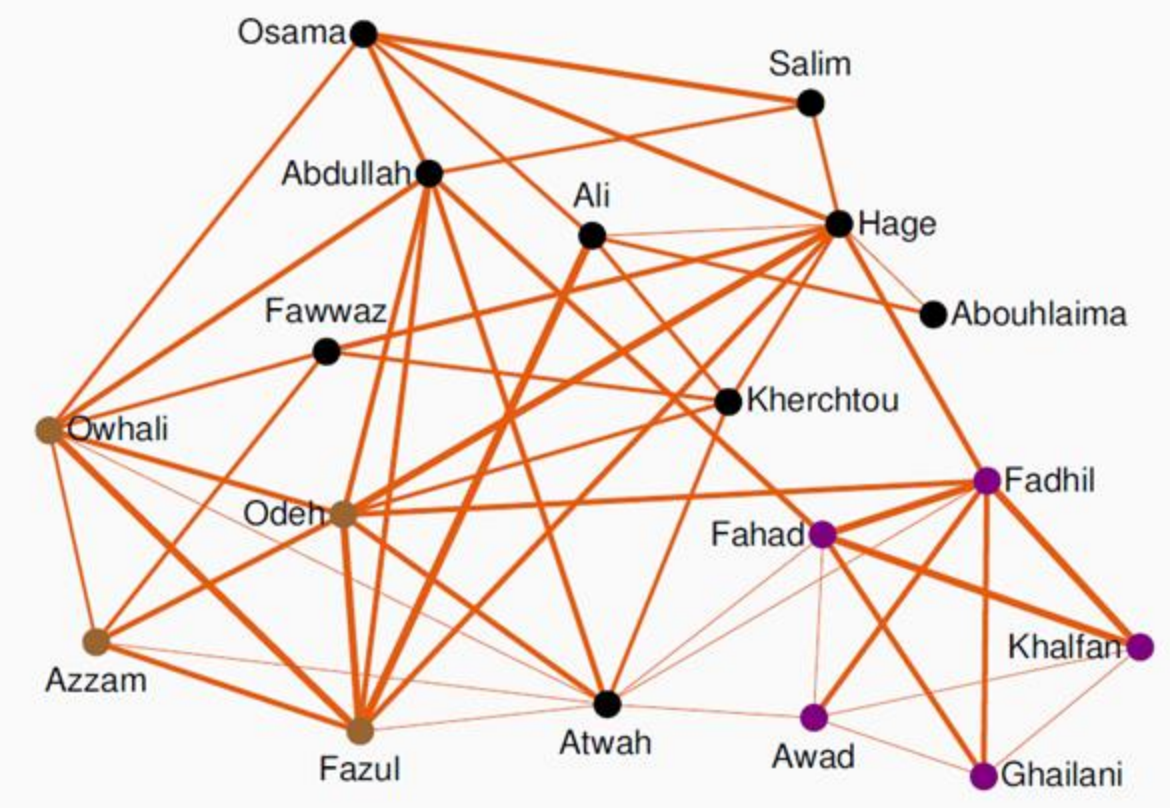

Rodzaje grafów

- grafy proste
- grafy skierowane
- multigrafy
- grafy ważone
- grafy warstwowe

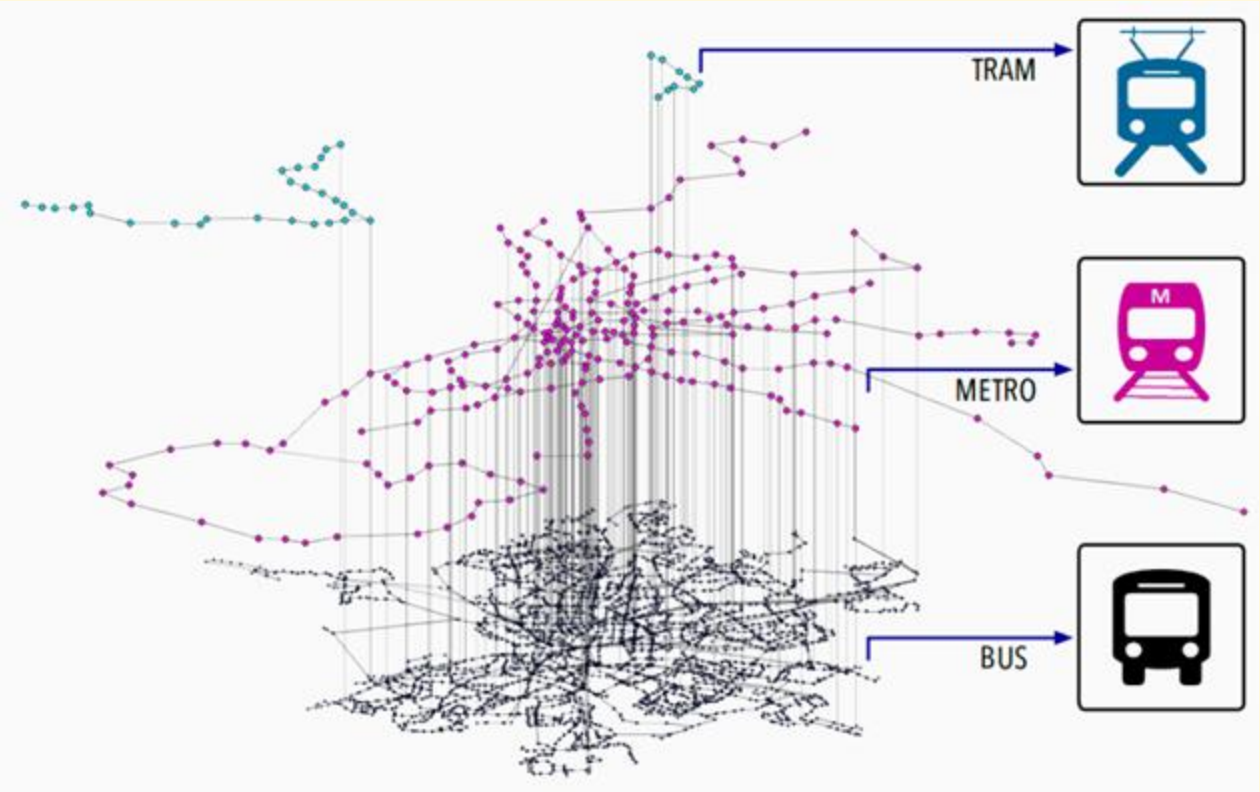

Rodzaje grafów

- grafy proste
- grafy skierowane
- multigrafy
- grafy ważone
- grafy warstwowe
- hipergrafy

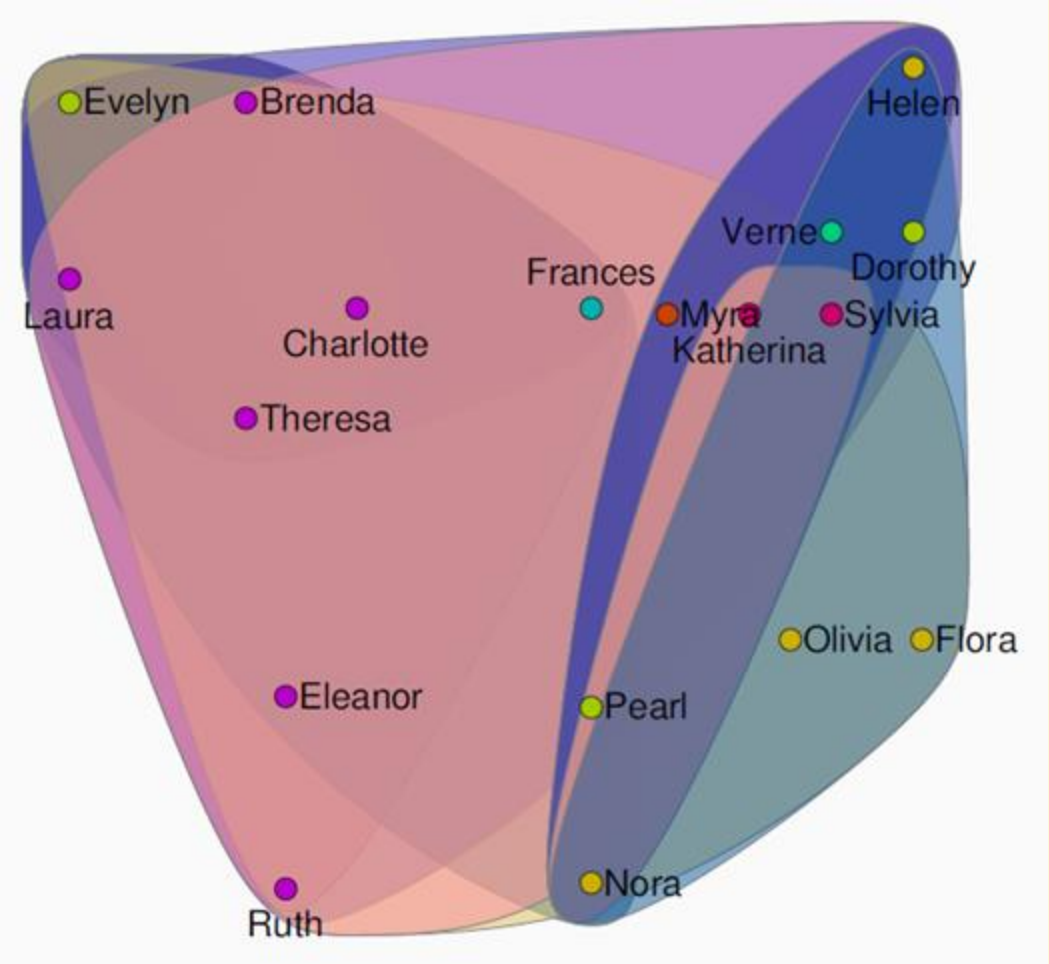

1. Złożone grafy są trudne do zrozumienia bez dobrej wizualizacji.

1. Złożone grafy są trudne do zrozumienia bez dobrej wizualizacji.

2. Wizualizacje pomagają w komunikacji i eksploracji sieci.

1. Złożone grafy są trudne do zrozumienia bez dobrej wizualizacji.

2. Wizualizacje pomagają w komunikacji i eksploracji sieci.

3. Niektóre grafy są zbyt duże, aby rysować je ręcznie.

1. Złożone grafy są trudne do zrozumienia bez dobrej wizualizacji.

2. Wizualizacje pomagają w komunikacji i eksploracji sieci.

3. Niektóre grafy są zbyt duże, aby rysować je ręcznie.

Potrzebujemy algorytmów, które automatycznie rysują grafy, aby były one bardziej dostępne dla ludzi.

1. Algorytmiczne rozwiązania potrzebują konkretnych formatów danych.

1. Algorytmiczne rozwiązania potrzebują konkretnych formatów danych.
2. Istnieje wiele formatów w których można przechowywać informacje o grafie (.csv, .json, .gml, .pajek, .dimacs, …).

1. Algorytmiczne rozwiązania potrzebują konkretnych formatów danych.
2. Istnieje wiele formatów w których można przechowywać informacje o grafie (.csv, .json, .gml, .pajek, .dimacs, …).
3. W większości przypadków nie mamy pełnej kontroli nad dokładnym rozłożeniem wierzchołków.

1. Algorytmiczne rozwiązania potrzebują konkretnych formatów danych.
2. Istnieje wiele formatów w których można przechowywać informacje o grafie (.csv, .json, .gml, .pajek, .dimacs, …).
3. W większości przypadków nie mamy pełnej kontroli nad dokładnym rozłożeniem wierzchołków.
4. Często spotykamy grafy dużych rozmiarów, które są trudne do wizualizacji, ze względu na: mnogość wierzchołków, nachodzenie labeli, nakładające się krawędzie, długi czas rysowania grafu.

1. Algorytmiczne rozwiązania potrzebują konkretnych formatów danych.
2. Istnieje wiele formatów w których można przechowywać informacje o grafie (.csv, .json, .gml, .pajek, .dimacs, …).
3. W większości przypadków nie mamy pełnej kontroli nad dokładnym rozłożeniem wierzchołków.
4. Często spotykamy grafy dużych rozmiarów, które są trudne do wizualizacji, ze względu na: mnogość wierzchołków, nachodzenie labeli, nakładające się krawędzie, długi czas rysowania grafu.

Wizualizacja grafów jest skomplikowana i nie ma uniwersalnych reguł jak to robić. Niektórych informacji nie da się ukazać samym obrazkiem.

Jak mierzyć grafy?

1. Współczynnik klasteryzacji (clustering coefficient)
2. Długość najdłuższej ścieżki / średnica grafu
3. Gęstość sieci (2E/N)
4. Największy stopień wierzchołka (celebryta)
5. Indeks Hirsch’a
6. PageRank
7. Próg epidemii
8. Liczba Erdos’a
9. Liczba Bacon’a

Liczba Erdos’a

Minimalna ścieżka współautorstwa artykułów prowadząca od naukowca A do Paula Erdos’a. Wartość dla Paula Erdos’a jest równa 0.

MR Collaboration Distance = 3

Grzegorzewski, Przemysław	coauthored with	Mesiar, Radko	MR3660830
Mesiar, Radko	coauthored with	Širáň, Jozef	MR4171596
Širáň, Jozef	coauthored with	Erdős, Paul[1]	MR1297187

MR Collaboration Distance = 4

Cena, Anna	coauthored with	Gągolewski, Marek	MR4240238
Gągolewski, Marek	coauthored with	Mesiar, Radko	MR3158692
Mesiar, Radko	coauthored with	Širáň, Jozef	MR4171596
Širáň, Jozef	coauthored with	Erdős, Paul[1]	MR1297187

Drzewo cnót głównych

Cztery cnoty kardynalne umieszczone są niżej niż trzy cnoty teologiczne. Z każdej z cnót głównych wyrastają cnoty niższego rzędu. *Speculum Virginum*, XII w.

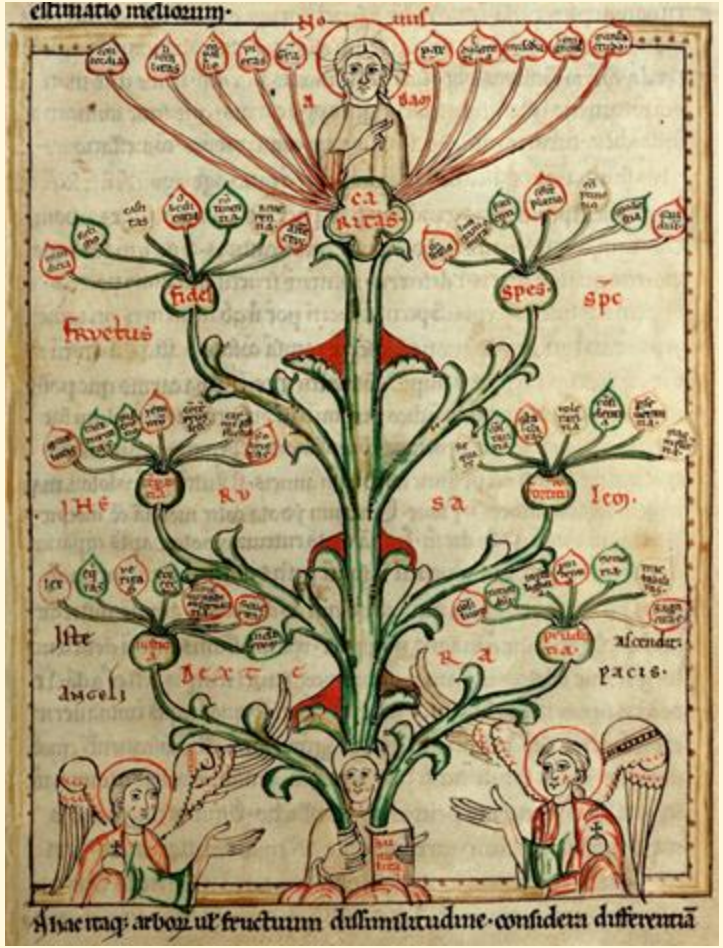

Drzewo genealogiczne (sieć społecznościowa)

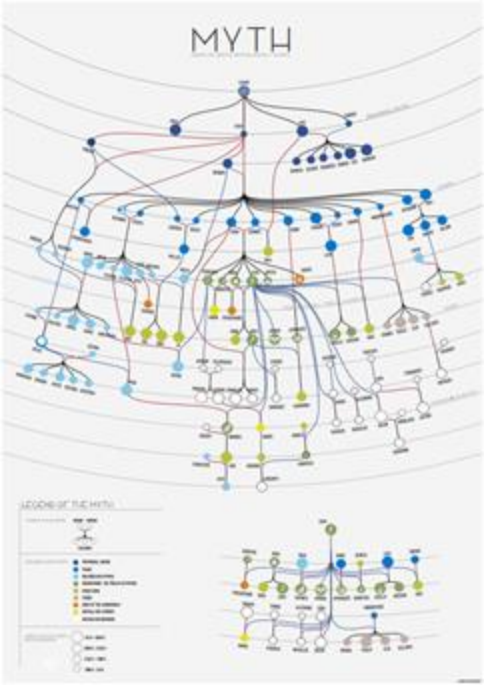

J. Klawitter, T. Mchedlidze, Link: go.uniwue.de/myth-poster

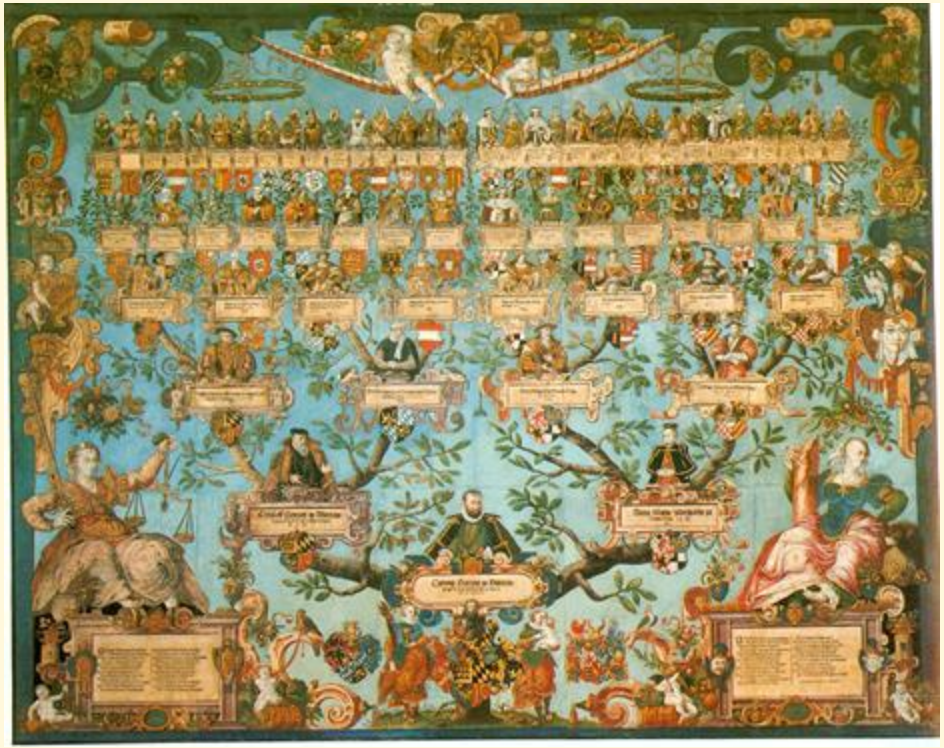

Ahnentafel Herzog Ludwig von W¨urttemberg, 1585

Graf cytowań (sieć społecznościowa)

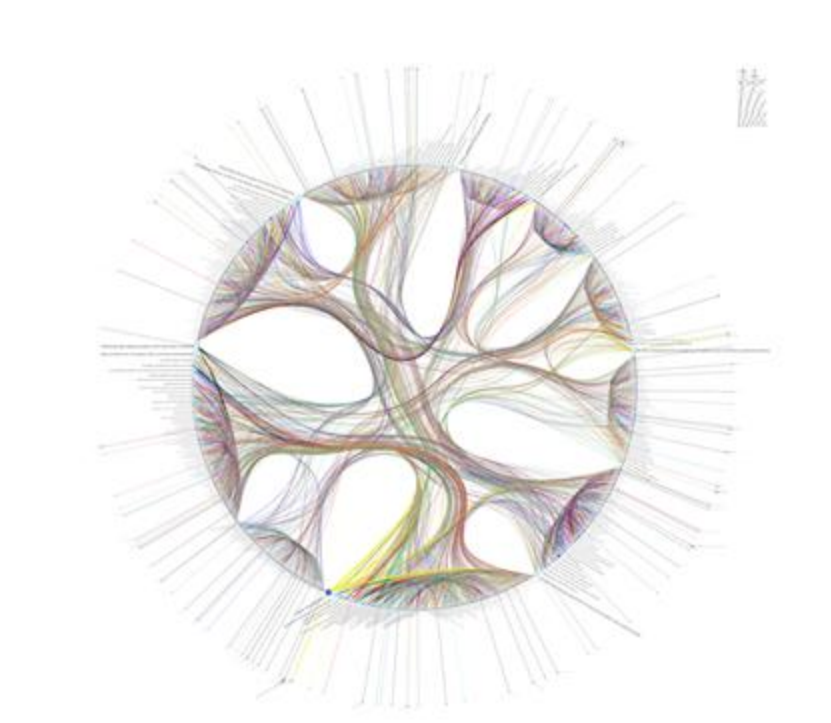

Da Ye, Link: https://go.uniwue.de/citation-graph

Kolej dużych prędkości w Europie (sieć komunikacyjn

https://pl.wikipedia.org/wiki/Kolej_du%C5%BCych_pr%C4%99dko%C5%9Bci_w_Europie

Sieć ludzkich chorób (bioinformatyka)

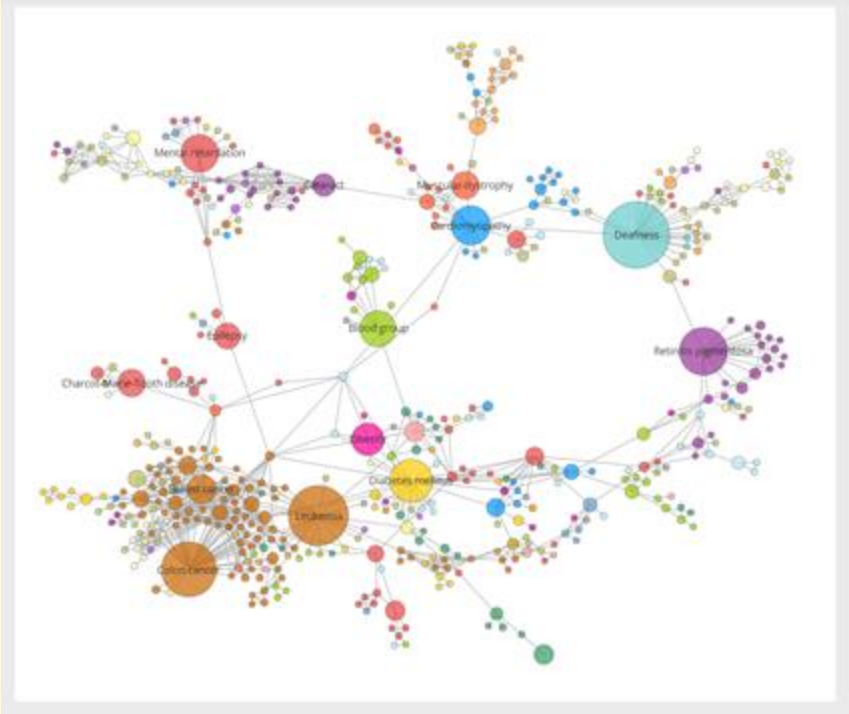

https://en.wikipedia.org/wiki/Human_disease_network

THESE CHARTS SHOW MOVIE CHARACTER INTERACTIONS.
THE HORIZONTAL AXIS IS TIME. THE VERTICAL GROUPING OF THE LINES INDICATES WHICH CHARACTERS ARE TOGETHER AT A GIVEN TIME.

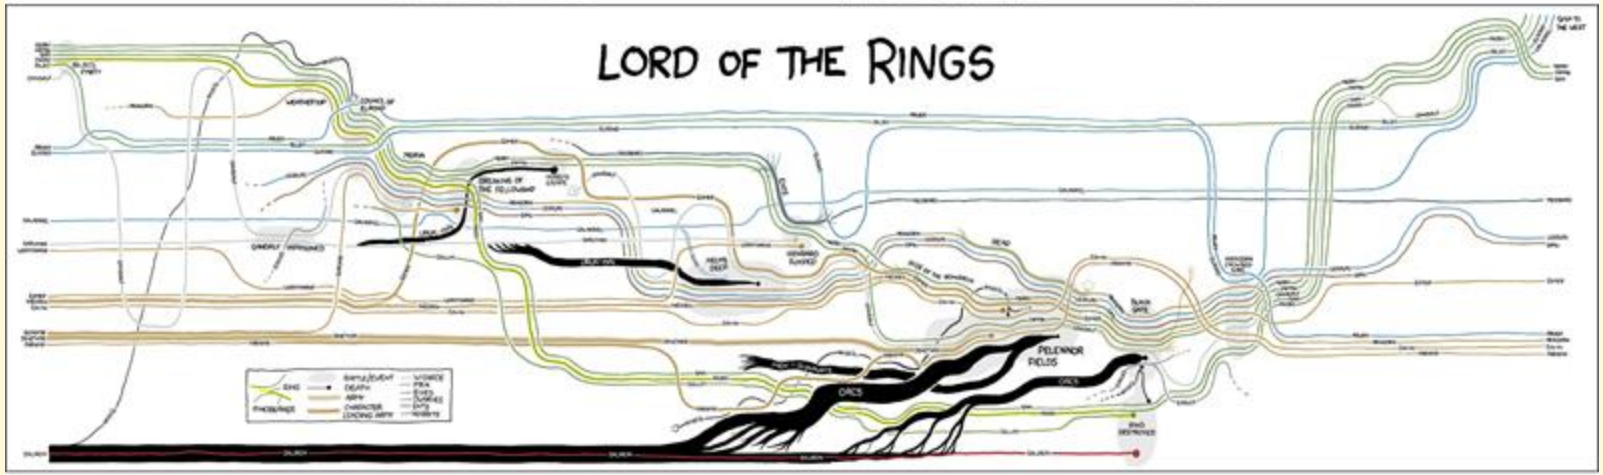

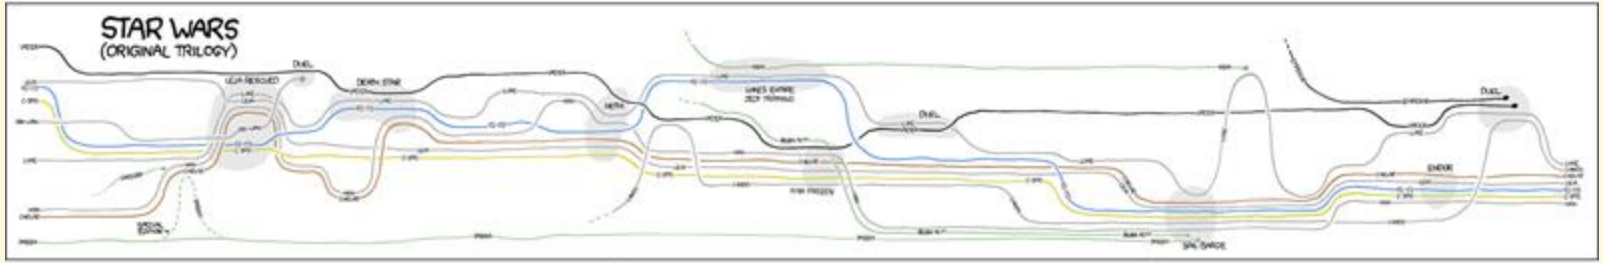

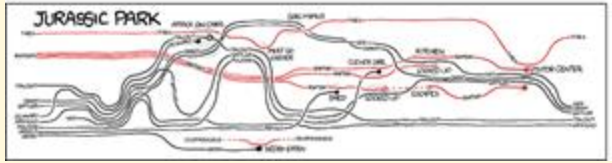

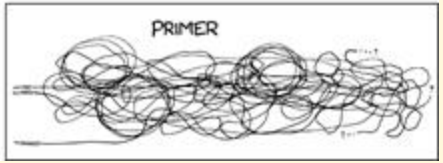

https://xkcd.com/657/

- https://seafile.rlp.net/f/f36d7e005a3c48a2bac2/
- Przedmiot Social Networks & Recommendation Systems na studiach magisterskich Data Science - dr inż. Grzegorz Siudem
- The Anatomy of a Search Engine: Sergey Brin and Lawrence Page